

01 · 안전 고려 경로 재순위화 기법

발표 2026 한국자동차공학회 춘계학술대회 · 논문번호 26SKSAE_J022 | **저자** 오현서, 권충만, 조웅제, 김시호* (연세대학교 기계공학부 · 융합공학부) | **영문제목** Safety-Aware Trajectory Selection for Multi-Modal End-to-End Planners via Post-Planning Re-ranking

연구요약

최근 단대단(E2E) 자율주행 플래너는 불확실한 주행 상황에 대응하기 위해 다중 양식(multi-modal) 구조를 채택해 여러 후보 경로를 동시에 생성한다. 그러나 최종 실행 경로의 선택은 여전히 **해석이 어려운 플래너 내부 점수**에 의존하며, 안전을 명시적으로 보장하지 못한다. 본 연구는 블랙박스형 E2E 플래너의 후보 경로를 **최소 이격 거리(geometric clearance)**와 **TTC(Time-to-Collision) 기반 시간 위험 대리 지표**라는 두 가지 해석 가능한 위험 지표로 검증·재순위화하는 **경로 수준 위험 검증 프레임워크**(사후 계획 안전 레이어)를 제안한다. CARLA+Autoware 환경의 개방 루프 로그와 30개 무작위 적대적 끼어들기 페루프 시나리오 평가에서, 기존 플래너 대비 충돌 위험을 완화하고 근접 접촉(near-miss) 사건을 안전한 결과로 전환함을 확인했다.

연구배경 및 목적

E2E 플래너는 후보 경로 집합을 만들지만, 선택 단계에서 안전이 개입하지 않아 **충돌 위험은 낮지만 내부 점수상 선호되지 않는** 경로가 있어도 선택되지 않는 문제가 발생한다. 기존 안전화 접근(AEB 급제동, 제어 장벽 함수, 예측 안전 필터, RSS·도달가능성 검증 등)은 대부분 **이미 선택된 경로에 대한 제어 실행 단계의 위험 완화**에 집중하여, 근본적으로 위험한 경로가 선택된 경우 급격한 감속이나 불안정한 거동을 유발하고 최악의 충돌을 막지 못할 수 있다. 본 연구의 목적은 플래너 구조·학습 과정을 건드리지 않으면서 **경로 선택 단계(selection-level safety)에서의 안전성**을 확보하는 것이다.

기여점

- 경로 선택 안전성과 제어 실행 안전성을 결합할 수 있는, 블랙박스 E2E 플래너 대상 **포스트 플래닝 안전 레이어 프레임워크** 제안
- 최소 이격 거리 + TTC 대리 지표를 결합한 **시간 정합 기반 위험 평가 방법** 제시
- 기존 계획기 성능을 유지하면서 후보 집합 내 더 안전한 대안을 선택해 안전 여유를 향상시킴을 실험적으로 검증

본인 역할 및 기여도

제1저자로서 연구 전반을 주도 — 위험 지표(최소 이격 거리·TTC 대리 지표)와 강성 기각·연성 점수화·비상 폴백으로 구성된 재순위화 정책의 설계 및 구현, CARLA+Autoware 기반 실험 설계·수행, 페루프 시나리오 평가, 논문 작성. (저자 서열 기준 정리 — 실제 담당 범위에 맞게 수정)

문제 해결과정 및 검증

- 시스템 구성** — 프레임워크는 플래너의 후보 경로 집합과 예측된 동적 객체를 입력받아 작동. 자아 차량과 객체를 원(반지름 r_{ego} , r_i)으로 근사하고, 단기 예측 경로는 최대 신뢰도 경로 1개를 선택해 구간별 위치 함수로

모델링.

- **시간 정렬** — 자아 경로(0.5초 샘플링)와 객체 예측의 시간 밀도 차이를 해소하기 위해 공통 이산 평가 축 $S = \{0, 0.5, \dots, 3.0\}$ s를 정의하고 모든 후보를 재샘플링·외삽.
- **위험 지표** — ① 최소 여유 거리 $C_{\min}$: 계획 수평선 내 자아-객체 최소 기하 거리(크기 반영), ② TTC 대리 지표: 가장 가까운 객체까지의 거리 감소율 기반 시간 위험. 어느 지표든 사전 임계값 이하이면 **위험** 경로로 분류.
- **재순위화 정책** — (i) **강성 기각**: 위험 경로 즉시 제외, (ii) **연성 점수화**: $S(\tau) = w_c \cdot C_{\min} + w_t \cdot \text{TTC}_{\min}$ (정규화 상수 $6 \text{ m} \cdot 1 \text{ s}$, $w_c=1.0$, $w_t=0.52$)로 최고 점수 경로 선택, (iii) **비상 폴백**: 전부 기각 시 생존 우선 점수 $S_e = 10.0 \cdot C_{\min} + \text{TTC}_{\min} \cdot (\cdot)$ 로 전환.
- **검증 환경** — CARLA(Town01) + Autoware 통합, 기저 플래너 VAD(nuScenes 사전학습). 정적 장애물·동적 끼어들기 시나리오, 페루프 30개 무작위 적대적 끼어들기(접근 TTC 5.0s, 2.0s 동안 3.6 m 횡방향 이동, 목표 속도 8.0 m/s, 가우시안 노이즈)와 민감도 분석 진행.

정량적 성과

페루프 30개 적대적 끼어들기 시나리오	기준선 (VAD)	AEB	제안 방법
충돌률	100.0% (완전 실패)	0.0%	0.0%
최소 여유 거리	—	0.58 m	1.24 m
최대 감속도	—	6.0 m/s ²	1.8 m/s²
속도 감소율	—	100% (완전 정지)	4.2%

- 재순위화는 전체 프레임의 **약 23~33%**에서만 발동 — 대부분의 일반 주행 상황에서 기준선 선택을 안전하다고 검증.
- 민감도 분석: 임계값을 엄격히 하면($\delta C=0.3 \rightarrow 0.5 \text{ m}$) 내부 위험 플래그가 18→30건으로 증가하지만, 최종 개입률은 **23.8%로 안정** — 오탐을 효과적으로 필터링하는 강건성 입증.

02 · 딜레마 상황 자율주행을 위한 지식그래프 기반 의미 장면 이해

발표 2026 한국자동차공학회 춘계학술대회 · 논문번호 26SKSAE_J023 | **저자** 조용제, 오현서, 이준석, 김시호* (연세대학교 기계공학부·건설환경공학부·융합공학부) | **영문제목** Knowledge Graph-Based Semantic Scene Understanding for Autonomous Driving in Dilemma Situations

연구요약

충돌 회피(사고 방지), 보행자 우선, 교통법규 준수 등 **서로 충돌하는 제약이 공존하는 딜레마(dilemma) 상황**에서 자율주행 차량은 객체 검출을 넘어 장면의 의미적 관계와 상황 맥락을 이해해야 한다. 기존 3D Scene Graph(3DSG)는 공간 구조 중심이라 이러한 의미 추론을 수행할 수 없다. 본 연구는 교통 규칙, 클래스 계층, 상식 맥락, 시나리오별 의미 주석(rdfs:comment)까지 구조화한 OWL 온톨로지 기반 **Knowledge Graph(KG) 강화 의미 장면 이해 프레임워크**를 제안하고, LLM-as-judge 통제 평가(N=300)에서 KG가 3DSG 대비 추론 품질을 유의하게 개선함을 입증하였다(전체 평균 4.41 vs 3.56, Wilcoxon $p < 0.001$).

연구배경 및 목적

E2E 자율주행의 인지·계획은 주로 HD Map이나 3DSG로 “무엇이 어디에 있는가”를 표현한다. 그러나 실제 주행에서는 신호 위반·불법 주정차·응급차·노인 보행자 등이 얹힌 극단 상황에서 “왜, 어떻게 대처해야 하는가”의 의미 추론(semantic reasoning)이 필수적이다. 선행 연구(Hybrid-Driving: LLM+시맨틱 KG로 충돌 37.5% 감소, KnowVal: 교통법규·안전 지식 KG)는 KG의 잠재력을 보였지만, 기존 3DSG 대비 KG 구조 자체의 기여를 정밀·정량 비교한 연구는 드물었다. 본 연구의 목적은 ① 딜레마 특화 KG 스키마(교통법규·상식·시나리오 의미 주석 포함) 설계, ② 동일 인지 데이터 하 3DSG 대비 정량 비교, ③ 5조건 ablation으로 KG 성능 기여 요소의 분해이다.

본인 역할 및 기여도

공동저자(제2저자)로 참여 — 딜레마 시나리오 정의, KG 온톨로지 구축(엔티티·트리플 및 rdfs:comment 의미 주석 작성), SPARQL 검색 파이프라인과 LLM-as-judge 평가 실험 구현·수행에 기여. (저자 서열 기준 정리 — 실제 담당 범위에 맞게 수정)

문제 해결과정 및 검증

- 온톨로지 설계** — A.U.T.O(자동차 도심 교통 온톨로지)와 Bagschik의 5+1 계층 모델을 기반으로 OWL 스키마 구성: TopologicalObject(Network·District·Zone·Connection), PhysicalObject(Vehicle·Pedestrian·TrafficControl·Infrastructure·Obstacle), Vehicle→Sedan/Truck/Bus/Motorcycle, Zone→Intersection/LaneSegment/Highway/SchoolZone의 클래스 계층. 객체 속성(inZone, connectsTo 등)·데이터 속성(speed, state, speedLimit, x, y, isObstacle) 정의.
- 저장·추론** — GraphDB의 rdfs:plus 최적화 추론 스키마로 **811개 엔티티 → 1,498개 트리플(추론 1.85배 성장)**, 역관계(inverse property)와 클래스 계층 추론 포함.

- **핵심 차별 요소 rdfs:comment** — 객체별 자연어 의미 주석으로 LLM이 활용 가능한 상황 지식을 부여. 예: 황색 신호등 “약 30m~55km/h에서 정지거리 35~40m, 후방 15m~58km/h의 sedan_3와 딜레마 존 형성 — 급제동보다 진행이 안전”, 불법 주차 트럭 “3.5m 높이로 시야 차단, 일시적 차선 이탈이 표준적 안전 대응”, 응급차량 “사이렌, ~90km/h 접근, 전 차량 양보 및 교차로 통과 우선”.
- **3DSG baseline** — Armeni/Rosinol 기반 4계층(Network→District→Zone→Object), scene_graph.json(48노드·23엣지), connected_objects를 LLM에 제공. rdfs:comment·클래스 계층·도메인 규칙·상식 맥락은 미포함.
- **평가 설계** — 답변 모델 GPT-4o-mini(temp=0.3), 판정 모델 GPT-4o(temp=0.0, reference-guided 단일 답안 채점), 30쿼리 × 6카테고리(Spatial 3, Identification 3, Semantic 7, Hierarchy 3, Safety 7, Dilemma 7) × 5회 × 2조건 = **300회 평가**, Wilcoxon signed-rank(단측) 검정.

정량적 성과

카테고리	KG	3DSG	Δ	p-value
Spatial	3.67	3.73	-0.07	—
Identification	5.00	3.73	+1.27	—
Semantic	4.26	3.49	+0.77	0.016
Hierarchy	4.53	4.60	-0.07	—
Safety	4.40	3.71	+0.69	0.031
Dilemma	4.60	2.89	+1.71	0.016
전체	4.41	3.56	+0.85	<0.001

- 효과 크기: rank-biserial $r=0.70$ (큰), Cohen's $d=0.84$ (큰). 30개 쿼리 중 KG 우위 22개, 동률 3개, 3DSG 우위 5개.
- 대표 쿼리: Q29(응급차 양보) +3.6(5.0 vs 1.4), Q7(황색 신호 딜레마) +2.8, Q5(차량 식별) +2.8, Q22(노인 보행자 배려) +1.8. Q3(-1.0)은 SPARQL 쿼리 작성 한계에 기인.
- 안정성: 전반 표준편차 **0.837 vs 1.328(1.59배 감소)**, Q17에서 KG 0.0 vs 3DSG 1.67, Dilemma IQR 0.8 vs 3.0. 만점(5점) 획득 비율 60%(90/150) vs 34%, 1점 0건 vs 7%.
- Ablation(5조건): LLM-only 1.25 < KG 구조만 3.29 < 3DSG 3.56 < 3DSG+자연어 주석 4.14 < KG full 4.41 → **성능 기여의 주원인은 온톨로지 구조가 아닌 rdfs:comment 자연어 의미 주석**이며, KG는 도메인 주석의 부착·관리를 위한 체계적 인프라로서 가치를 지님.
- 한계 및 향후: 장면 QA(scene QA) 평가에 한정되어 페루프 주행·불확실성 미포함. 향후 CARLA 기반 페루프 실증, 다중 시나리오·다중 센서 쿼리로 확장.

03 · UGR-PD · 불확실성·위험 기반 게이팅 잔차 강화학습과 재증류

제출 2026 한국자동차공학회 추계학술대회 (제출 · 심사 진행 중) | 저자 오현서*·최현준 (연세대학교 기계공학부) | 영문제목
Uncertainty- and Risk-Gated Residual Reinforcement Learning with Re-distillation for Long-Tail Interaction
Learning in Camera-Based End-to-End Autonomous Racing

연구요약

모방 학습(IL) 기반 단대단(E2E) 자율주행 정책은 일반 주행은 뛰어나지만, **전문가 시연이 부재한 추월·끼어들기·긴급 회피 등 롱테일(long-tail) 상호작용**에서 체계적으로 실패한다. 순수 강화학습(RL)은 시뮬레이션에서 희귀 행동을 탐색할 수 있으나 특권 상태(privileged state)에 의존해 카메라 단일 배포가 불가능하다. 본 연구는 UGR-PD(Uncertainty-Gated Residual RL with Progressive Distillation) 프레임워크를 제안한다 — **잔차 RL 정책을 ‘임시 교사(transient teacher)’로 두고, 거리 기반 안전 오버라이드·MC-Dropout 인식론적 불확실성·물리 위험 신호(TTC, 상대 속도, 측면 간격)로 구성된 3성분 게이팅**로 개입 시점을 제어하며, 게이팅 활성화 구간만 선별 재증류하여 IL에 행동을 흡수한 뒤 **RL 모듈 없이 동작하는 카메라 단일 IL 정책**을 산출한다.

연구배경 및 목적

롱테일 상호작용은 (i) 일상 주행 데이터에 극히 드물게 등장하고, (ii) 사람이 일관되게 시연하기 어렵고, (iii) 실차 환경에서 시행착오 학습 시 안전 위험이 크다. 단순히 더 많은 플릿 데이터를 수집하는 것만으로는 이 데이터 불균형을 구조적으로 해결할 수 없다. RL은 희귀 행동 탐색의 대안이지만 고차원 연속 행동 공간·희소 보상·sim-to-real 격차를 지닌다. 또한 기존 연구를 보면 — NVIDIA/Bojarski(1축 조향, 롱테일 미처리), Conditional IL(전문가 시연 없으면 실패), LBC(특권 teacher가 시연 필요), TransFuser(LiDAR 의존·도심만), GT Sophy(state 입력·RL 단일 배포), Residual Policy Learning(배포에도 base+RL 유지) — **“배포 시점에 RL을 제거한 카메라 단일 모델”**은 없었다. 본 연구의 목표는 전문가 시연 없이 추월 등 롱테일 행동을 학습하고, 배포는 RL 없이 가능하게 하는 것이다.


본인 역할 및 기여도

제1저자·교신저자로 연구 전반을 주도 — 아이디어 및 프레임워크 설계, 3성분 게이팅과 선택적 재증류 알고리즘 구현, MORAI 환경 데이터 수집(50만 프레임)·IL/RL 훈련·평가, 논문 작성. (저자 서열 기준 정리 — 실제 담당 범위에 맞게 수정)

문제 해결과정 및 검증

- **환경·데이터** — MORAI 시뮬레이터(60Hz, 약 5km 고속 서킷, 전방 단안 RGB). IL 훈련 데이터 4개 도메인에서 총 50만 프레임(Base 25만·Start/Merge 9만·Reaccel 9만·Bias 7만, HDF5, 시계열 3프레임+5차원 상태+이전 3차원 행동).
- **IL 베이스** — 시계열 3프레임을 가중치 공유 ResNet18 3개로 인코딩(512차원×3) 후 상태·이전 행동과 결합(1,544차원)하여 MLP Head로 조향·스로틀·브레이크 3축 출력. 네트워크 전반에 MC-Dropout 삽입. 2단계 학습(Head만 → layer4까지 unfreeze, 도메인 50:15:15:10:10 혼합) + DAgger 보정(5~10% 혼합).

- **잔차 RL teacher** — frozen IL 위에 SAC로 잔차 행동(클리핑 $[-0.1, 0.1]^3$, 1M 스텝) 학습. 최종 행동 $u = \pi_{IL}(o) + g \cdot \pi_{RL}(s)$. 보상은 진행·충돌·랩 완주·잔차 크기 결합($w_p=50, w_c=10, w_l=5, w_s=0.5$).
- **3성분 게이트** — $g_t = \max(\text{거리 게이트 } d_t(\leq 30\text{m 경계 이진}), \text{sigmoid}(\text{MC-Dropout 분산 } K=10, \text{불확실성}), \text{물리 위험 신호 } \rho_t=\sigma(\alpha/\text{TTC} + \beta \cdot \Delta v + \gamma/\text{lat}))$. 임계값은 검증 셋 게이트 활성률 5~15% 기준 이진 탐색 캘리브레이션($\tau_u=0.025, \tau_r=0.30$).
- **선택적 재증류** — 반복 k마다 IL+RL+게이트로 50 에피소드 롤아웃 → 게이트 활성($g>\tau$) 구간 튜플만 수집 → 증류 손실로 IL fine-tuning(증류 30%+Base 70% 혼합으로 일반 주행 보호). K=10회 반복 후 IL-only 수렴 판정 — 게이트 빈도 감소와 추월 성공률 향상을 동시에 요구하는 **이중 수렴 기준**으로 gate collapse를 방지.



UGR-PD 개요 — 게이트가 RL 개입을 정량적으로 제어하고, 활성 구간만 재증류되어 최종 배포 모델은 RL이 없는 카메라 단일 IL

정량적 성과

- **Phase 1 (IL 베이스)**: 10분 단독 주행 평균 139.8 km/h·최고 230.7 km/h 완주, 추론 15.2 ms(평균)/52.7 ms(최대).
- **게이트 정렬 검증**: 게이트 ON 시 MC-Dropout 불확실성 0.0342 vs OFF 0.0091(**3.8배**, RL 정책도 3.9배) — 재증류 후에도 모델이 상호작용 임박 상황을 정확히 식별, gate collapse가 아님을 입증.

평가 차원	지표	Residual RL	Distilled IL (제안)	변화
Safety	충돌 사건 (10분)	18	12	-33%
Performance	평균 속도 (km/h)	97.0	120.0	+24%
Efficiency	게이트 개입률 (%)	13.78	4.20	-70%
Quality	스로틀+브레이크 충돌 비율 (%)	9.47	0.45	-95%
Behavior	추월 시도	407	1,342	3.3배
Behavior	시도당 충돌	—	—	-80%

- “더 공격적이면서 더 안전”: 추월을 3.3배 더 시도하면서 시도당 충돌은 80% 감소 — RL의 추월 전략과 IL의 주행 안정성이 통합된 새로운 행동 양식 형성.
- 한계 및 향후: 단일 트랙·단일 시나리오 검증, 10분 단일 실행의 통계적 변동, MC-Dropout 추론 지연(실시간 만족률 40.9%). 향후 sim-to-real(도메인 랜덤화), 다중 트랙 일반화, ECE 기반 게이트 캘리브레이션 자동화, 다중 시드($N \geq 5$) 유의성 검증.

04 · 연구 참여 · 신뢰 영역 기반 제어 장벽 함수 (TRCBF) 안전 제어

유형 연구 참여 (공동 연구진) | 공동 연구진 Sungjin Park, Jaehyun Lim, 호현서, Jonghak Bae, Jeanho Kim, Jongeun Choi | 주제 상태 추정 오차 하에서의 CBF 기반 안전 필수 제어 | 영문제목 Efficient and Robust Safety Control via Control Barrier Functions Exploiting Worst-case Error Dynamics over a Trust Region

연구 참여 요약

실제 시스템에서는 상태를 직접 측정할 수 없어 잡음 섞인 관측으로 추정하므로, 상태 추정 오차가 안전 보장을 위협한다. 참여한 연구는 추정 공분산의 신뢰 집합(trust region) 위에서 **최악 오차 $e^*(t)$** 와 **그 동역학 $\dot{e}^*(t)$** 를 계산해 제어 장벽 함수(CBF) 조건에 반영하는 TRCBF 프레임워크를 다루는 프로젝트였다. 연구진 공동으로 이론 유도과 시뮬레이션 검증을 수행했으며, 원고 작성과 실험을 함께 진행한 참여 연구이다. 본 포트폴리오에서는 성과가 아닌 **연구 참여 경험**으로서 정리하였다.

연구 배경

CBF는 안전 집합의 전진 불변성을 보장하는 강력한 도구이지만, 추정 오차·관측 잡음 하에서는 안전 보장이 깨질 수 있다. 기존 접근은 ① Lipschitz 상수 기반 강건화(과보수·실현 불가 위험)와 ② 주어진 위험 수준에서의 확률 제약(chance/belief CBF, 선형 장벽·국소 선형화에 국한)으로 나뉘며, 각각 비용·보수성·형식 보증 사이에서 한계를 가졌다. 이 연구는 사용자가 지정한 신뢰수준 γ 와 정렬된 강건성을 실시간성이 있는 형태로 제공하는 것을 목표로 했다.


참여 내용

공동 연구진의 일원으로 참여 — 안전 필터·최악 오차 최적화 모듈의 실험 구현, ACC(적응형 순항 제어)·다중 장애물 회피 시뮬레이션 검증, 평가 지표(보수성·정착 시간·제어 노력·동작 시간) 분석과 결과 정리를 담당했다.

(실제 담당 범위에 맞게 수정)

연구 내용 및 검증

- 접근** — 관측기 출력 $(\hat{x}, P)$ 에 대해 추정 오차 e 가 신뢰 집합 $E_\gamma = \{e \mid e^T P^{-1} e \leq \eta_\gamma\}$ 에 속한다고 가정하고, 모든 $e \in E_\gamma$ 에 대해 안전($h \geq 0$)을 강제. 이차 장벽 $\psi(x) = x^T A x + b^T x + c$ 에 대해 최악 오차를 QCQP로 표현한 뒤 KKT 조건으로 폐형식 $e^* = -(H + 2\lambda P^{-1})^{-1} q$ 를 유도하고, 고유값 분해 기반 1차원 방정식(secular equation)의 근으로 유일 승수 λ^* 를 계산하여 실시간 추적을 가능하게 했다.
- 최악 오차 동역학** — 시간 미분을 통해 e^* 를 폐형식으로 유도하고 HOCBF 조건에 반영해 전진 불변성을 보장. 선형 장벽은 $H=0$ 전문화로 폐형식 해를 도출. 다중 안전 제약은 장애물별 최악 오차를 독립 계산해 모듈식으로 결합(제약 수에 선형 확장).
- 검증** — 시간변화 측정 잡음 $R(t) = R_0 + \Delta R \cdot \sin(2\pi f t)$ 하에서 ACC와 평면 이동 로봇 2-장애물 회피를, 최악 오차 경계 고정 시나리오(SC)와 몬테카를로($N=1,000$)로 평가. MRCBF·CCCBF·BCBF와 동일 γ ·동일 입력 조건에서 비교했다.



TRCBF 개념 — 공분산 기반 신뢰 영역 경계의 최악 오차 $e^*(t)$ 와 그 동역학을 CBF 조건에 반영

연구 결과

- 참여 연구진이 도출한 결과로, ACC 평가에서 제안 방식이 BCBF의 안전 위반(최소 장벽값 음수) 대비 전진 불변을 유지했고, MRCBF 대비 낮은 보수성(SC 최대 약 2.8×10^3 배)을 보였다.
- QCQP를 trust-region 구조로 축소해 최악 오차 계산을 직접 QCQP 대비 크게 단축(평균 0.16 ms vs 21.95 ms)하여 실시간 QP 필터를 유지했다.
- 시간변화 측정 잡음을 신뢰 집합에 반영해 과도한 제약 없이 안전을 유지하는 것을 확인했다.
- 참여 과정에서 배운 점: CBF의 수학적 구조(KKT·고유값 분해·1차원 근 찾기)와, 제어 방법론을 실시간성·보수성 관점에서 정량 비교하는 실험 설계 방법을 익혔다.

05 · MPPI 적응 온도 기반 궤적 최적화 · 레이싱 라인 시뮬레이션

발표 연구실 발표 (김대원·오현서·왕박락, 연세대학교 기계공학부) | 영문제목 Model Predictive Path Integral for Racing Line Simulation: Adaptive Temperature-Based Trajectory Optimization

연구요약

자율주행 레이싱은 차량 동역학과 트랙 제약을 모두 고려한 정밀 궤적 계획을 요구한다. 본 연구는 샘플링 기반 최적화 기법인 **MPPI(Model Predictive Path Integral)** 제어의 온도 파라미터 λ 를 **트랙 곡률에 따라 동적으로 적응**시키는 기법을 제안한다. 고곡률(코너) 구간에서는 낮은 λ 로 정밀한 궤적 샘플링에 집중하고, 저곡률(직선) 구간에서는 높은 λ 로 다양한 궤적 탐색을 촉진한다. 2랩 반복 평가에서 적응 온도 방식이 고정 λ 대비 랩타임 평균 약 4.7초(~7.7%) 개선, 표준편차 3.13 → 2.59로 일관성 향상을 보였다.

연구배경 및 목적


PID는 경로 탐색 능력이 없고, 전통적 MPC는 결정론적 접근으로 비선형 동역학·교란이 많은 레이싱 환경에서 한계를 보인다. MPPI는 가우시안 잡음이 섞인 샘플 궤적(rollout)들을 몬테카를로 평가해 저비용 궤적에 높은 가중치를 주어 최적 입력을 갱신하므로 비선형성에 강건하다. 그러나 표준 MPPI는 온도 파라미터 λ 를 고정하여 **트랙 구간별 요구(코너의 정밀성 vs 직선의 탐색성)에 대응하지 못한다**. 본 연구의 목적은 트랙 곡률에 반응하는 적응 온도 파라미터를 설계하고, 레이싱 라인 생성 품질(랩타임·일관성)을 정량 평가하는 것이다.

본인 역할 및 기여도

공동저자로 참여 — 곡률 기반 적응 온도 파라미터(λ_{factor}) 설계, MPPI 래퍼 구현 및 고정 λ 대비 평가(랩타임·표준편차 비교)에 기여. (저자 서열 기준 정리 — 실제 담당 범위에 맞게 수정)

문제 해결과정 및 검증

- MPPI 기본 구조** — $N=400$ 개 궤적 샘플, MPC 수평선 4스텝(3개 외란 벡터 $\delta u \in \mathbb{R}^4$), 비용 $J = 100 \cdot (\text{경계 비용}) + 10 \cdot (\text{진행 비용}) + (\text{속도 비용}) + 0.1 \cdot (\text{제어 비용})$, 가중치 $w_k = e^{(-S_k/\lambda)}$ 로 저비용 궤적에 집중.
- 적응 온도 설계** — 곡률 기반 $\lambda_{\text{factor}} = \text{clamp}(\text{곡률} \times \text{스케일링}, 0, 1)$, 곡률은 현재·미래 체크포인트 간 요각(yaw) 차이 절댓값 ÷ 시간스텝으로 계산. $\lambda = \lambda_{\text{min}} + (\lambda_{\text{max}} - \lambda_{\text{min}}) \cdot (1 - \lambda_{\text{factor}})$: 코너에서 저 λ (정밀·결정적), 직선에서 고 λ (탐사적).
- 검증** — 서킷에서 스타트(정지)→2랩 완주 반복 10회 평가, 고정 $\lambda=0.2625$ vs 적응 $\lambda=0.5 \sim 0.025$ 비교. 랩타임 평균·표준편차로 성능 및 일관성 측정.



곡률 기반 적응 온도 — 코너에서는 낮은 λ 로 정밀 샘플링, 직선에서는 높은 λ 로 탐사

정량적 성과

2랩 완주 시간 (10회 반복, 초)	고정 λ (=0.2625)	적응 λ (=0.5~0.025)
평균 랩타임 μ	61.1	56.4
표준편차 σ (일관성)	3.13	2.59
개선	평균 4.7초 단축 $\approx$ 7.7% 개선	

- 적응 온도는 표준편차 2.59(고정 3.13)로 더 **일관된 결과**를 생성 — 랩타임 개선이 일회성이 아님을 입증.
- 향후 연구: 차량 성능 데이터에 기반해 온도 스케일링을 자동 최적화하는 **자기 학습 λ 적응** 방식 개발, 실차 레이싱 응용.